

Machine Learning

Progetto di Paolo Acone



Indice contenuti



Obiettivo del progetto

Preprocessing dei dati

Modello utilizzato

Risultati e conclusioni

Notebook completo





Il progetto ha lo scopo di costruire un modello di Machine Learning per prevedere la **probabilità di sopravvivenza dei passeggeri del Titanic**.

Dataset: Titanic_sub **Features principali:**

- Sesso (Maschio/Femmina)
- Età
- Classe del biglietto
- Porto di imbarco



Preprocessing dei dati

- Separazione del target, ovvero la colonna che ci indica se una persona è sopravvissuta o meno, dalle altre caratteristiche
- Codifica delle variabili categoriche:
 - Sesso → Label Encoding (0 = femmina, 1 = maschio).
 - Porto di imbarco → One-hot encoding per trasformare la variabile in numerica
- Conversione dei dati in intero per compatibilità con il modello
- Suddivisione del dataset:
 - Training set (75%) di cui il 25% destinato al Validation Set
 - per scegliere la profondità ottimale.
 - Test set (25%) → per valutare le prestazioni finali



Modello utilizzato Decision Tree

Ottimizzazione del modello

• Testato l'iparametro k, rappresentante la massima profondità dell'albero, con valori: 2, 5, 10, 25 e profondità massima sui dati del **set di validazione**

In particolare otteniamo che la versione ottimizzata del modello si ha con il valore:

• k=10



Osservazioni principali

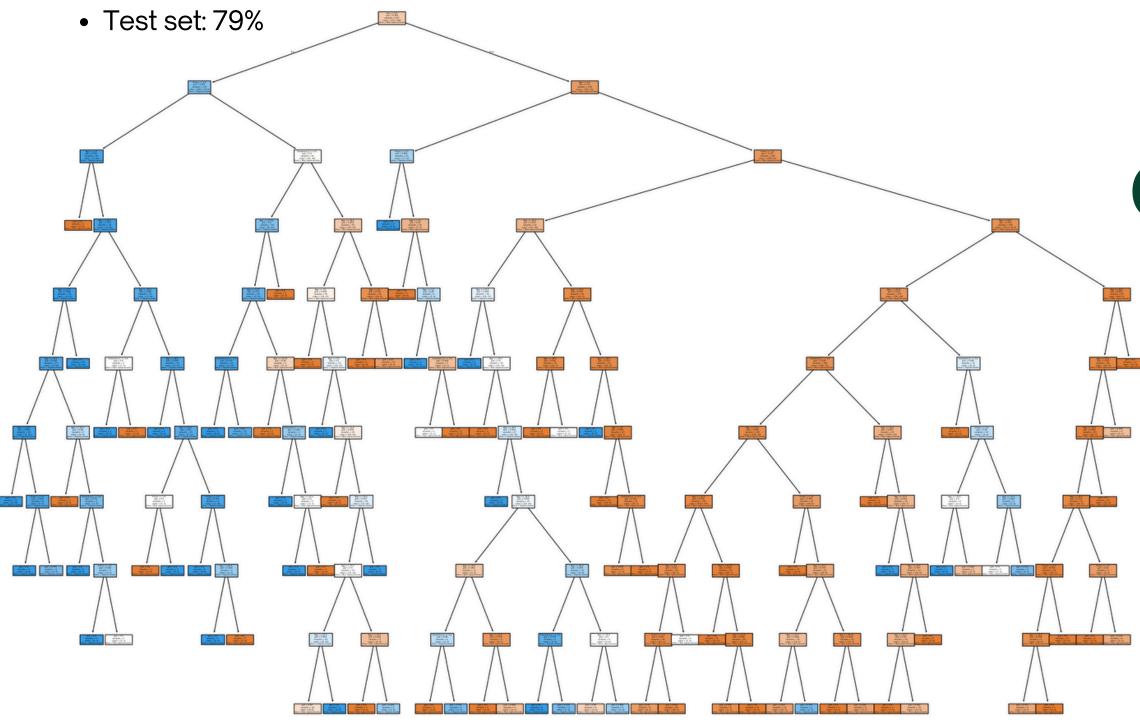
- Il valore ottimale di **k** pari a 10 ci dà un modello abbastanza complesso
- L'albero ha un cospicuo numero di nodi, con un'analisi dettagliata delle variabili;
- La struttura sottolinea l'importanza di sesso, classe e età, con una segmentazione articolata;
- Il modello mantiene bene l'accuratezza sui dati di test, siamo sul 79% rispetto all'82% risultante dai test di validazione.

Risultati e Conclusioni



✓ Accuratezza del modellocon k=10

• Validation set: 82%



Albero decisionale



<u>Il notebook completo con codice e analisi è</u> <u>disponibile ai seguente link</u>

Link al notebook

Notebook Completo



